Relatório – Projeto de Álgebra Linear (CIN0138)

Equipe 9: Wallyson Rodrigues da Silva, Guilherme Duque e Bruno Antônio

Ideia

Começamos pelas estratégias do laboratório do site (médias e efeitos de linha e coluna). Elas funcionam em algumas matrizes do banco público, mas em outras o erro fica perto de 1, igual a chutar a média. Olhando os valores singulares dos gabaritos, vimos que quase todas as matrizes têm posto baixo (entre 1 e 6), ou seja, podem ser escritas como

$$X \approx U\,V^{\top}, \quad \text{com } U\ (m \times r) \text{ e } V\ (n \times r) \text{ e } r \text{ pequeno.}$$

Uma matriz de posto r tem só r(m + n − r) valores livres, então as entradas conhecidas podem ser suficientes para achar U e V, e o produto devolve as ocultas.

Como o código funciona

1. **Normalização.** Tiramos a média e dividimos pelo desvio das entradas conhecidas. As ocultas (NaN) viram zero e não entram nas contas.
2. **Efeitos de linha e coluna.** Modelo $x_{ij} \approx \mu + a_i + b_j$, ajustado alternando a média dos resíduos das linhas e das colunas. É o nosso plano B.
3. **Posto baixo por mínimos quadrados alternados.** Com V fixo, cada linha de U é um problema de mínimos quadrados com r incógnitas, resolvido pelas equações normais $(V^{\top}V + \lambda I)\,u = V^{\top}x$ usando só as colunas conhecidas daquela linha. Depois fixamos U e resolvemos V, e repetimos. O ponto de partida vem da SVD da matriz com zeros nas ocultas. O λ evita que o sistema fique instável quando a linha tem poucas entradas conhecidas.
4. **Escolha do posto.** O posto certo muda de matriz para matriz e errar por 1 já estraga o resultado (na matriz 9, posto 4 dá erro 0,004 e posto 5 dá 0,43). Como não temos o gabarito, escondemos uma parte das entradas conhecidas, ajustamos com o resto e medimos o erro nas que foram escondidas (validação cruzada). Testamos postos de 1 a 12 e vários valores de λ e ficamos com o de menor erro.
5. **Cuidados.** Com λ muito pequeno algumas previsões saíam absurdas, então limitamos o quanto a previsão pode se afastar da versão com λ maior. No fim misturamos o posto baixo com o modelo de efeitos, e se nenhum dos dois ganhar da média na validação devolvemos a média (caso de matriz sem estrutura). Também garantimos que a saída não tenha NaN nem infinito.

Resultados (banco público, NRMSE)

Matriz	Tamanho	Efeitos	Vizinhas	Nosso código
1	8x8	1,264	1,310	1,234
2	9x6	0,033	0,043	0,034
3	6x9	0,077	0,371	0,076
4	14x5	0,303	0,231	0,041
5	14x7	0,453	0,268	0,162
6	16x16	1,115	0,906	0,042
7	18x22	1,054	0,752	0,088
8	17x17	1,066	1,208	1,003
9	24x19	0,248	0,266	0,001
10	28x31	0,327	0,335	0,001
Média		0,594	0,569	**0,268**

"Efeitos" e "Vizinhas" são as duas melhores estratégias do laboratório. Nas matrizes de posto baixo (4, 6, 7, 9 e 10) o erro cai bastante, e nas 9 e 10 a reconstrução é quase exata. As matrizes 1 e 8 não têm estrutura: nenhuma estratégia fica abaixo de 1 e o código devolve a média. Para não depender só dessas 10 matrizes, testamos também em matrizes geradas por nós, de até 40x40; o pior tempo foi de cerca de 0,4 s por matriz.

Limitações

Quando a matriz não tem estrutura, ou quando uma linha ou coluna está toda oculta, não há informação para recuperar e o resultado fica perto da média. Em matrizes muito pequenas a validação tem poucas entradas e pode escolher um posto que não é o melhor.

Referências

- G. Strang, MIT 18.06, aulas 16 (mínimos quadrados) e 29 (SVD).
- Laboratório "Matriz oculta" e links do site da disciplina (fatoração de matrizes).
- Documentação do NumPy (`numpy.linalg.svd` e `numpy.linalg.solve`).